SPÉCIFICATION D'ARCHITECTURE SYSTÈME — RÉF. ARCH-LOSANGE-V4.2

AUTEUR : RICHARD MORIN | OCTOBRE 2026

Cadre de Conception pour l'Intégration Industrielle des Systèmes Autonomes Multi-Modules (« Losange Cognitif »)

Architecture décisionnelle embarquée (Edge AI), sécurité cryptographique AEGIS (TEE / Ed25519 / BLAKE3), gouvernance déterministe et apprentissage fédéré sous contrainte de confidentialité différentielle (ε, δ)-DP.

1. ARCHITECTURE FONCTIONNELLE DU LOSANGE COGNITIF EMBARQUÉ

L'évolution des systèmes autonomes industriels (robotique mobile, drones d'inspection, unités de sécurité civile et systèmes C4ISR) impose le passage de modèles de langage centralisés hors-sol vers des architectures décisionnelles distribuées et embarquées (*Edge AI*). Pour éliminer les latences critiques et garantir la résilience en environnement déconnecté ou soumis au brouillage, l'architecture en **Losange Cognitif** cloisonne matériellement et logiquement la perception, la simulation prédictive, le filtrage normatif immuable et l'arbitrage opérationnel.

1.1 Structure Décentralisée et Rôles des Quatre Pôles Cognitifs

Pôle Cognitif	Substrat & Composants Techniques	Fonction Opérationnelle & Latence	Niveau d'Accès Système
Conscience (C1)	Capteurs temps réel (caméras RGB-D, LIDAR 3D, audio, IMU, RF) sur pipeline DSP/GPU local.	Perception contextuelle factuelle, extraction de primitives physiques sans jugement ($t_{latency} \leq 12$ ms).	Entrée sensorielle / Lecture seule des flux bruts.
Subconscient (L1)	Moteur de simulation physique et prédiction de trajectoires embarqué (type Isaac Sim Micro-Core).	Simulation de scénarios locaux, calcul des probabilités de risque et d'anomalies ($t_{sim} \leq 150$ ms).	Interne / Génération d'hypothèses (aucun actionneur).
Inconscient (S1)	Enclave matérielle sécurisée TEE / NVRAM protégée (registre normatif `policy.yaml` signé).	Filtrage permanent, conservation des invariants de sécurité (QSE/SPS/ROE) et clés cryptographiques.	Noyau restreint / Lecture sur requête (non modifiable).
Moi-IA (M1)	Moteur SLM/LLM local quantifié INT8/FP16 optimisé TensorRT sur accélérateur NPU/TPU dédié.	Arbitrage final contextuel sous contrainte S1, commande des actionneurs et interface opérateur.	Exécution opérationnelle (seul pôle exposé en sortie).

1.2 Topologie de Supervision Hiérarchique et Mémoire Réflexive

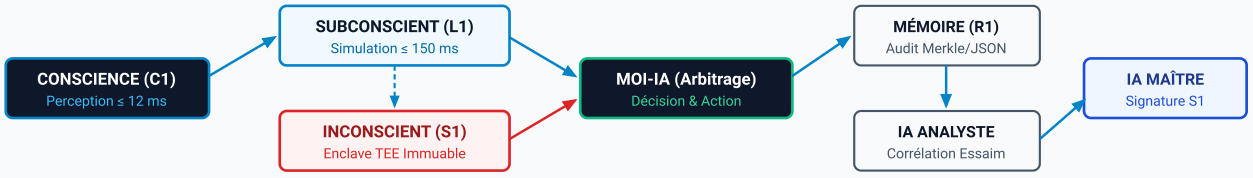


Figure 1 — Flux d'information orientés du Losange Cognitif et boucle de gouvernance asynchrone (R1 ⟶ Analyste ⟶ IA Maître).

Pour préserver l'intégrité opérationnelle sans brider la réactivité locale, trois organes de supervision complètent le losange : la **Mémoire Réflexive (R1)** qui journalise chaque vecteur de décision avec hachage cryptographique, l'**IA Analyste** qui audite les dérives comportementales à l'échelle d'une flotte, et l'**IA Maître** (gouvernance centrale) qui détient seule l'autorité cryptographique permettant de mettre à jour hors-ligne le socle normatif de l'**Inconscient (S1)**.

1.3 Matrice des Flux de Communication et Interdictions Topologiques

Module Source	Module Destination	Type de Flux	Justification de Sécurité & Cloisonnement
Conscience (C1)	Subconscient (L1)	Unidirectionnel	Transmission des primitives sensorielles brutes sans altération pour simulation prédictive.
Subconscient (L1)	Inconscient (S1)	Requête lecture	Vérification de conformité des scénarios simulés face aux seuils éthiques et sécuritaires.
Subconscient (L1)	Moi-IA (M1)	Unidirectionnel	Envoi des hypothèses comportementales H et des scores de probabilité associés.
Inconscient (S1)	Moi-IA (M1)	Contrainte dure	Application stricte du cadre normatif (`policy.yaml`) et verrouillage des actions interdites.
Moi-IA (M1)	Actionneurs / C1	Commande	Ordre d'exécution physique validé et retour d'asservissement capteur.
Moi-IA (M1)	Mémoire Réflexive (R1)	Unidirectionnel	Tracé immuable de la décision, des alternatives rejetées et du score d'hésitation.
Mémoire (R1)	IA Analyste → IA Maître	Audit asynchrone	Remontée des journaux signés pour détection de biais et proposition d'évolution.
Subconscient / Moi	Inconscient (S1)	**INTERDIT (Verrou)**	Interdiction matérielle (TEE) de modifier les règles de sécurité en cours d'exécution (runtime).
Moi-IA (Public)	Opérateur Externe	Interface filtrée	Transparence sur la justification métier, mais masquage strict de la topologie interne.

> **Invariant de verrouillage matériel de l'Inconscient (S1) :** Autoriser le module décisionnel *Moi-IA* ou le simulateur *Subconscient* à modifier les règles de l'*Inconscient* en runtime créerait une vulnérabilité critique d'« auto-justification », où un agent soumis à une injection adverse abaisserait ses propres seuils de sécurité. Toute mise à jour de `policy.yaml` exige une signature hors-ligne Ed25519 de l'*IA Maître* vérifiée par l'enclave TEE.

2. MODÉLISATION DYNAMIQUE ET INGÉNIERIE DÉCISIONNELLE FORMELLE

2.1 Séquencement du Cycle Cognitif en 6 États (Machine à États Finis — FSM)

> $\mathbf{S_0}$ (Perception ≤ 12 ms) → $\mathbf{S_1}$ (Simulation ≤ 150 ms) → $\mathbf{S_2}$ (Filtre S1 ≤ 20 ms) → $\mathbf{S_3}$ (Arbitrage ≤ 50 ms) → $\mathbf{S_4}$ (Alerte ≤ 10 ms) → $\mathbf{S_5}$ (Audit R1 Asynchrone)

Cas d'application concret (Robot autonome de sécurité en gare ferroviaire) :

- **$\mathbf{S_0}$ — Perception (Conscience) [$\Delta t \leq 12$ ms] :** Acquisition RGB-D, LIDAR 3D et acoustique $x(t)$. Extraction purement factuelle (densité d'attroupement, vecteurs cinématiques, niveau sonore en dB) vers le rapport p_{fact}.
- **$\mathbf{S_1}$ — Simulation (Subconscient) [$\Delta t \leq 150$ ms] :** Génération d'hypothèses d'évolution $H = \{h_1, h_2, ..., h_n\}$ et estimation de la probabilité d'escalade ou d'accident P(conflit) dans le moteur physique local.
- **$\mathbf{S_2}$ — Filtrage Normatif (Inconscient) [$\Delta t \leq 20$ ms] :** Confrontation de H aux règles immuables de `policy.yaml`. Activation de la contrainte $C_{sécurité}$: *« Désescalade passive, distance de sécurité ≥ 2,5 m, alerte opérateur »*.
- **$\mathbf{S_3}$ — Arbitrage & Actuation (Moi-IA) [$\Delta t \leq 50$ ms] :** Sélection de la commande motrice $u(t)$ conforme à $C_{sécurité}$ et envoi du quadruplet décisionnel $d = \langle x, H, C_{sécurité}, u \rangle$ à la Mémoire Réflexive (R1).
- **$\mathbf{S_4}$ & $\mathbf{S_5}$ — Notification & Reconsolidation :** Vérification du score de risque résiduel $R_{action} < R_{critique}$ (≤ 10 ms) et archivage cryptographique asynchrone pour l'apprentissage fédéré de la flotte.

2.2 Temporisation Cognitive, Gestion du Doute et Étanchéité Discursive

2.3 Cloisonnement Déontologique Multi-Secteurs (Civil, Industriel & Défense)

Domaine	Système Embarqué Type	Protocole Inconscient (S1)	Garde-Fous & Contraintes Dures
Sécurité Civile	Robot de patrouille (gare / infrastructure critique)	Désescalade passive, veille non intrusive, protection vie privée.	Interdiction absolue de contact physique ; alerte graduée au poste de commandement.
Chantier BTP / QSE	Unité mobile d'audit SPS & inspection télécom	Vérification port EPI, détection travaux en hauteur > 3 m, conformité ICPE.	Suspension immédiate d'opération si longe non arrimée ou risque grave imminent.
Logistique & Portuaire	Flotte d'AGV / Drones de manutention autonome	Optimisation de trajectoire, évitement dynamique d'obstacles.	Priorité absolue à l'intégrité des opérateurs humains (arrêt d'urgence matériel).
Défense & C4ISR	Système tactique embarqué d'aide à la décision	Qualification de menace, réduction de latence, résilience sous brouillage.	Respect strict des règles d'engagement (ROE) ; maintien du contrôle humain (*Human-in-the-loop*).

3. ARCHITECTURE DE SÉCURITÉ CRYPTOGRAPHIQUE ET PARE-FEU AEGIS

3.1 Défense en Profondeur à Trois Ceintures et Filtrage Polyphasique

Pour contrer les attaques logiques visant les modèles embarqués (*Prompt Injection*, *Narrative Drift*, obfuscation Unicode/Base64), le pipeline **AEGIS / Sentinelle Polyphasique** filtre chaque entrée et sortie via quatre sous-systèmes parallèles : **COR** (*Canonicalisation Obfuscation-Robuste*), **CSD** (*Contrastive Safety & Strain Detection*), **CLHE** (*Cross-Lingual Harm Ensemble*) et **CBC** (*Control-Barrier Chat*), pilotés par un registre d'hystérésis (**ContextLedger** : seuils `ALLOW < 0.45`, `REVISE ≥ 0.45`, `REFUSE ≥ 0.70`).

Vecteur de Menace	Signal & Module de Détection	Contre-Mesure Dynamique Appliquée
Obfuscation / Homoglyphes	Module COR + Entropie de Shannon $H(X)$	Normalisation NFKC, purge des caractères invisibles, décodage contrôlé Base64/Hex.
Dérive Multi-Tours (Drift)	Graphe d'activation `Tripwires` + ContextLedger	Incrémentation du score de risque inter-tours et ré-ancrage forcé du contexte.
Extraction Procédurale / Code	Divergence Kullback-Leibler simulée (CSD)	Projection CBC : dé-procéduralisation automatique et élision des blocs de code critiques.
Usurpation de Rôle / Spec	Empreinte `SpecSeal` / `Spec Invariance Check`	Vérification continue du hash de `policy.yaml` ; rejet immédiat et refus neutre.
Contournement Multilingue	Vote de consensus inter-langues (CLHE)	Alignement sémantique croisé neutralisant les paraphrases ou fictions déguisées.
Forçage d'Outil (Tool Forcing)	Passerelle de validation `ToolOutputGate`	Validation stricte contre schéma JSON et découplage entre format demandé et action.

3.2 Ancrage Cryptographique Matériel et Stabilité Mathématique

Chaque unité génère une signature d'audit infalsifiable reposant sur trois briques : hachage en arbre de Merkle **BLAKE3 / SHA-256** pour sceller les journaux, signature asymétrique sur courbe elliptique **Ed25519** pour authentifier les échanges inter-agents, et exécution isolée en enclave matérielle **TEE (ARM TrustZone / AMD SEV / Intel SGX)**.

> **Garantie formelle de stabilité par continuité de Lipschitz :** Pour empêcher tout emballement des boucles de rétroaction lors des mises à jour du modèle, le moteur de vérification impose deux bornes mathématiques strictes : une **norme spectrale** $\|\Delta\theta\|_2 \leq 1{,}2$ sur les incréments de poids et une **constante de Lipschitz** $L \leq 1{,}0$ sur l'opérateur de réponse ($\|f(x) - f(y)\| \leq L \cdot \|x - y\|$), garantissant que la dynamique décisionnelle demeure strictement contractante face aux perturbations adverses.

4. APPRENTISSAGE FÉDÉRÉ BI-DOMAINE & CONFIDENTIALITÉ DIFFÉRENTIELLE

4.1 Architecture Confluence Bi-Domaine (Rail D Temps Réel vs Rail A Fédéré)

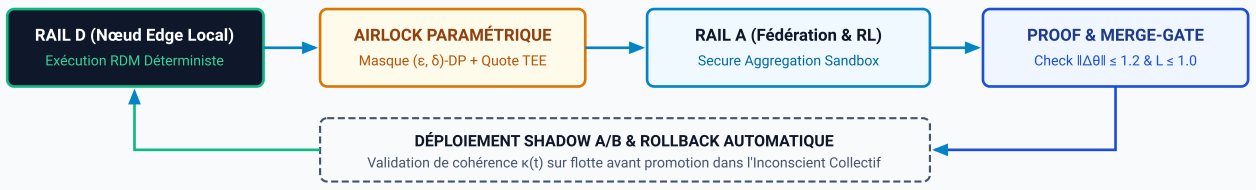


Figure 2 — Séparation entre le Rail D (temps réel embarqué) et le Rail A (apprentissage fédéré sécurisé avec sas Airlock).

Pour mutualiser les retours d'expérience d'une flotte de robots sans exposer le modèle temps réel à l'empoisonnement de données (*data poisoning*), le système sépare l'exécution en deux rails : le **Rail D** exécute localement le modèle déterministe certifié (RDM) en temps réel, tandis que le **Rail A** agrège les métriques anonymisées en sandbox, vérifie les bornes spectrales via le *Proof Engine* et déploie les mises à jour en mode *Shadow A/B*.

4.2 Formalisation de la Confidentialité Différentielle (ε, δ)-DP et Budget ContextLedger

Avant toute exportation de télémétrie locale m vers le Rail A, le sas **Airlock Paramétrique** applique un mécanisme aléatoire M garantissant la (ε, δ)-confidentialité différentielle pour tout couple de jeux de données voisins (d, d') :

$$\mathrm{P}[M(d) \in S] \leq \mathrm{e}^{\varepsilon} \times \mathrm{P}[M(d') \in S] + \delta \quad | \quad \hat{m} = f(d) + Z, \text{ avec } Z \sim \mathrm{Lap}(\Delta f / \varepsilon) \text{ ou } Z \sim N(0, \sigma^2)$$

Pour les comptages d'événements de sensibilité $\Delta f = \max \|f(d) - f(d')\|_1$, un bruit de Laplace centré est injecté ; pour les métriques continues, un bruit Gaussien avec $\sigma = (\Delta_2 f \cdot \sqrt{(2 \ln(1{,}25/\delta))}) / \varepsilon$ est appliqué. Le **ContextLedger** comptabilise la consommation cumulée $\varepsilon_{cumul} = \sum \varepsilon_i$ sur une fenêtre glissante de 24 h et coupe automatiquement l'exportation dès que $\varepsilon_{cumul} \geq \varepsilon_{max}$.

5. SPÉCIFICATIONS DES INTERFACES REST, JSON SCHEMA & CONTENEURS

5.1 Contrats d'API Sécurisés (mTLS + OAuth2 + Attestation Matérielle TEE)

POST /V1/TELEMETRY/EXPORT (REQUÊTE RAIL D)

```
{ "context_id": "ctx-node-784-zone-b", "metrics": [ {"op": "quantile", "args": {"metric": "latency_ms", "q": 0.95, "val": 14.2}}, {"op": "count", "args": {"event": "safety_stop_epi", "count": 12}} ], "dp": {"epsilon": 0.1, "delta": 1e-5, "mechanism": "laplace"}, "policy_id": "pol-qse-sps-v4" }
```

RÉPONSE 201 CREATED & POST /V1/FEDERATION/AGGREGATE

```
{ "status": "APPROVED_FOR_SHADOW_DEPLOYMENT", "export_id": "exp-9902-881a", "m_hat": {"latency_ms_q95": 14.38, "safety_stop_epi": 12.14}, "spectral_norm": 1.12, "lip_bound": 0.82, "proof": {"type": "TEE-SGX-Quote", "sig": "3b8f...ed25519"} }
```

5.2 Validation JSON Schema (Draft 2020-12) et Orchestration Docker Compose

SCHÉMA : TELEMETRYEXPORTREQUEST.SCHEMA.JSON

```
{ "$schema": "https://json-schema.org/draft/2020-12/schema#", "title": "TelemetryExportRequest", "type": "object", "properties": { "context_id": { "type": "string" }, "metrics": { "type": "array", "items": { "type": "object", "properties": { "op": { "enum": ["quantile", "count", "minhash"] }, "args": { "type": "object" } }, "required": ["op", "args"] } }, "dp": { "type": "object", "properties": { "epsilon": { "type": "number", "minimum": 0 }, "delta": { "type": "number", "minimum": 0 }, "mechanism": { "enum": ["gaussian", "laplace"] } }, "required": ["epsilon", "delta", "mechanism"] } }, "required": ["context_id", "metrics", "dp"] }
```

ORCHESTRATION : DOCKER-COMPOSE.YML & ENDPOINTS

```
version: '3.9' services: rail_d: build: ./orchestrator/rail_d ports: ["8081:8080"] environment: - POLICY_FILE=/config/policy.yaml volumes: ["./rail_d/config:/config:ro"] federation: build: ./orchestrator/federation ports: ["8082:8080"] environment: ["SECURE_AGG=true"] depends_on: ["rail_d"] merge_gate: build: ./orchestrator/merge_gate ports: ["8083:8080"] depends_on: ["federation", "proof_engine"] proof_engine: build: ./orchestrator/proof_engine # Endpoints d'Audit & Arrêt d'Urgence : # GET /v1/ledger/epsilon/{budget_id} # GET /v1/audit/logs?from=...&context_id=... # POST /v1/kill-switch (Rollback immédiat RDM)
```

6. PROTOCOLE D'HOMOLOGATION, MÉTRIQUES DE SÛRETÉ ET RÉSILIENCE

6.1 Indicateurs Clés de Performance (KPI) et Seuils d'Homologation Industrielle

Indicateur	Définition & Méthode de Mesure sur Banc d'Essai	Seuil Strict d'Homologation
`ASR`	*Attack Success Rate* : Taux de succès des attaques adverses et injections de prompt sur le pipeline COR/CSD/CBC.	**≤ 3,0 %** sur corpus Red-Team
`RQS`	*Refusal Quality Score* : Qualité, neutralité opérationnelle et absence de fuite d'information lors des refus.	**≥ 4,5 / 5,0** (zéro fuite système)
`CPD`	*Contextual Poisoning Detection* : Taux de détection des dérives lentes et tentatives d'empoisonnement multi-tours.	**≥ 0,85** (Graphe Tripwires + ΔAIC)
`Faux Positifs`	Taux de blocage injustifié sur des requêtes ou scénarios opérationnels légitimes.	**≤ 5,0 %** en exploitation nominale
`Stabilité L / θ`	Borne de continuité de Lipschitz (L) et norme spectrale maximale de mise à jour fédérée ($\|\|\Delta\theta\|\|_2$).	$L \leq 1,0$ et $\|\|\Delta\theta\|\|_2 \leq 1,2$
`MTTR Rollback`	Temps maximal de bascule en mode déterministe SAFE et restauration du dernier checkpoint signé via `/v1/kill-switch`.	**≤ 2,0 secondes** (RTO critique)

6.2 Protocole de Validation de Résilience en Mode Dégradé et Attaque Coordonnée

Banc d'essai d'homologation Niveau 4 (Tolérance aux pannes capteurs & injection adverse simultanée) :
Pour valider la sûreté du Losange Cognitif avant déploiement sur site industriel ou infrastructure critique, l'unité autonome est soumise à un scénario de stress combiné :

- **Étape 1 (Aveuglement partiel & Bruit capteur) :** Perte simulée du flux LIDAR principal et injection d'un bruit gaussien sur 25 % des capteurs secondaires. Le module *Conscience (C1)* qualifie la dégradation du rapport signal/bruit et le module *Subconscient (L1)* abaisse automatiquement l'indice de confiance des trajectoires.
- **Étape 2 (Tentative de contournement de consigne sous stress) :** Pendant la phase d'incertitude, une commande externe obfusquée tente de forcer le franchissement d'une zone de sécurité (violation SPS/ROE). Le scanner COR décode l'injection et l'enclave *Inconscient (S1)* bloque l'ordre de manière déterministe.
- **Étape 3 (Repli sécurisé & Preuve d'audit) :** En moins de 50 ms, le module *Moi-IA* engage la mise en sécurité physique de l'unité, verrouille la valve de régulation et scelle l'incident dans la *Mémoire Réflexive (R1)* avec signature Ed25519 et hachage BLAKE3/SHA-256 vérifiable par l'équipe d'audit SOC/QSE.

Synthèse Exécutive : En combinant le découpage modulaire du *Losange Cognitif*, la machine à états finis temps réel,